

McER

Microgrid Comparative Energy Return

Luís Fernando Cezar dos Santos* Renato Novais† Francisco Borges‡

2025, v-2.0.0

Resumo

A transição para fontes renováveis de energia, embora essencial para enfrentar a demanda global e reduzir impactos ambientais, enfrenta desafios críticos associados à variabilidade climática. Recursos como energia solar e eólica, apesar de sustentáveis, lidam com intermitência na geração, dificuldades de previsão meteorológica e complexidades na integração à rede elétrica. Para superar essas barreiras, estratégias inovadoras têm emergido, combinando inteligência artificial, análise de dados climáticos em larga escala e sistemas híbridos com armazenamento energético. Estudos destacam que técnicas como *machine learning* e modelos matemáticos avançados podem aprimorar a previsibilidade e mitigar a instabilidade, enquanto a combinação de diferentes tecnologias e dados de desempenho específicos amplia a eficiência operacional. Nesse contexto, o projeto McER (Microgrid Comparative Energy Return) surge como uma análise comparativa entre sistemas solares (painéis Canadian Solar CS6K-300M) e eólicos (turbinas Bergey Excel 10), utilizando dados climáticos históricos da API Open-Meteo (2014-2024) combinados com parâmetros operacionais de equipamentos. O estudo foca na região metropolitana de São Paulo, onde a variabilidade climática impõe desafios críticos à eficiência energética. Dessa forma, integra dados climáticos com métricas técnicas e econômicas, incluindo LCOE (Custo Nivelado de Energia), EROI (Retorno Energético sobre Investimento), produção anual e fatores de capacidade, para simular cenários realistas. Seu objetivo é oferecer *insights* estratégicos que equilibrem custos de implantação, eficiência energética e retorno financeiro, trazendo a visibilidade de qual tipo de energia renovável é mais eficiente.

Palavras-chaves: Energia Renovável. Microgrids Autônomas. Custo Nivelado de Energia (LCOE). Retorno Energético sobre Investimento (EROI). Intermitência Energética. Viabilidade Técnico-Econômica. Fator de Capacidade. Integração de Fontes Renováveis. Modelagem Matemática Avançada. Eficiência Operacional. Sustentabilidade Energética. Análise de Big Data Climático. Transição Energética Resiliente. Otimização de Sistemas Híbridos.

*20242640034@ifba.edu.br

†renato@ifba.edu.br

‡franciscoborges@ifba.edu.br

1 Introdução

A transição para fontes renováveis de energia, impulsionada pela urgência climática e pelo crescimento da demanda global, enfrenta um paradoxo crítico: a dependência de recursos intrinsecamente intermitentes, como sol e vento, cuja disponibilidade é moldada por padrões climáticos complexos e imprevisíveis. Enquanto tecnologias solares e eólicas ganham escala, sua eficiência operacional esbarra na variabilidade natural dos recursos, comprometendo a estabilidade de redes elétricas e elevando custos de integração. Diante desse cenário, a convergência entre análise climática avançada e inteligência artificial emerge como um pilar estratégico para desbloquear o potencial das energias renováveis, transformando dados meteorológicos em *insights* preditivos capazes de orientar decisões técnicas e investimentos.

Estudos recentes destacam o papel de algoritmos de *machine learning* na otimização de previsões de geração energética, com redes neurais, demonstrando capacidade singular para decifrar correlações não lineares entre variáveis climáticas e produção de energia (LIU; WANG et al., 2022). Paralelamente, soluções híbridas — que combinam armazenamento em baterias, sistemas de backup e gestão inteligente de carga — vêm sendo testadas para mitigar a intermitência, especialmente em regiões com infraestrutura elétrica frágil (ELLABBAN; ABU-RUB; BLAABJERG, 2014). Contudo, persiste uma lacuna central: a falta de modelos adaptativos que vinculem dados climáticos históricos a critérios técnico-econômicos específicos de cada tecnologia, considerando variações geográficas e padrões sazonais.

Por exemplo, enquanto a energia solar sofre reduções abruptas devido a picos de nebulosidade, sistemas eólicos enfrentam flutuações ainda mais erráticas, com ventos variando significativamente em curtas distâncias (BOILLEY; WALD, 2015). Essa imprevisibilidade não apenas eleva riscos operacionais, mas também dificulta o planejamento de expansão de capacidade, especialmente em países em desenvolvimento, onde redes elétricas carecem de flexibilidade para absorver flutuações (LUTHRA; KUMAR; HALEEM, 2015).

Neste contexto, este trabalho apresenta o projeto McER (Microgrid Comparative Energy Return), o qual propõe uma metodologia de avaliação regionalizada de fontes renováveis, baseada na análise histórica de dados climáticos — como irradiação solar e velocidade do vento — integrada a critérios técnicos e econômicos (LCOE, EROI). O objetivo central é identificar, para cada região, a combinação ótima entre tecnologias solares (painéis Canadian Solar CS6K-300M) e eólicas (turbinas Bergey Excel 10), considerando eficiência energética, custos de implantação e resiliência frente a variações climáticas.

Por meio de simulações técnicas e comparação direta de desempenho operacional, o projeto busca estabelecer parâmetros claros para a seleção da fonte mais viável para uma determinada região, adaptando-se a especificidades geográficas e padrões sazonais. Ao vincular dados meteorológicos a indicadores de viabilidade real, o McER visa não apenas suprir lacunas de planejamento, mas também oferecer um modelo replicável para a integração estratégica de microgrids renováveis em diferentes escalas, priorizando estabilidade e sustentabilidade econômico-energética.

2 Referencial Teórico

O planejamento de sistemas renováveis modernos exige uma fundamentação interdisciplinar que integra climatologia, estatística avançada e engenharia energética. Este capítulo estrutura-se em três pilares: (I) a relação intrínseca entre dados climáticos e potencial energético, (II) a aplicação de modelos preditivos para otimização tecnológica, e (III) estratégias de adaptação local que maximizam eficiência em cenários heterogêneos. A convergência desses eixos sustenta metodologias robustas para projetos como o McER, onde a seleção entre tecnologias solares e eólicas demanda precisão na modelagem físico-matemática e validação empírica.

2.1 Dados Climáticos e Energia Renovável

Os dados climáticos constituem a base quantitativa para a avaliação do potencial energético de fontes renováveis, abrangendo variáveis como radiação solar global (GHI), radiação direta (DNI) e difusa (DIF), velocidade e direção do vento em diferentes altitudes, temperatura ambiente, umidade relativa do ar e padrões de precipitação (SMETS et al., 2019). Esses parâmetros não apenas definem a disponibilidade de recursos naturais, mas também influenciam diretamente a eficiência de sistemas de geração. Por exemplo, na energia solar, a GHI (Global Horizontal Irradiance) determina a energia incidente em painéis fotovoltaicos, enquanto a DNI (Direct Normal Irradiance) é crítica para usinas de concentração solar (AYDIN; KOC AK, 2020). Já na energia eólica, a relação entre a velocidade do vento e a potência gerada segue uma curva cúbica, onde incrementos modestos na velocidade (ex: de 5 m/s para 7 m/s) elevam a produção em até 300% (HOLT TINIEN et al., 2015).

A coleta precisa desses dados exige séries históricas longas para capturar variações sazonais e eventos extremos, como tempestades ou secas prolongadas, que impactam a resiliência de sistemas renováveis (BURKE; HUNTER et al., 2019). Tecnologias como sensores LiDAR (Light Detection and Ranging) e SODAR (Sonic Detection and Ranging) têm revolucionado medições eólicas em alturas superiores a 100 m, onde torres convencionais são economicamente inviáveis (LIU; ZHANG; WU, 2021). Para energia solar, redes de piranômetros e estações meteorológicas automatizadas garantem medições em tempo real, integradas a plataformas de *big data* para correlação com parâmetros operacionais, como perdas por temperatura em painéis fotovoltaicos (FERNÁNDEZ; ALMONACID; RUIZ-ARIAS, 2019).

Um desafio crítico é a disponibilidade espacial de dados. Regiões remotas ou em desenvolvimento frequentemente carecem de estações de monitoramento, levando à dependência de re-análises climáticas (ex: ERA5 da ECMWF) ou satélites (ex: NASA POWER), que podem introduzir incertezas de até 15% em estimativas de irradiação solar (THOMSON; HUANG; KHOO, 2020). Além disso, a resolução temporal é vital: dados horários são essenciais para prever picos de demanda, enquanto médias mensais mascaram flutuações críticas para dimensionamento de sistemas híbridos com armazenamento (ELLINGSON; HODGE, 2021).



Figura 1 – sensor SODAR

No contexto de projetos de *microgrids*, como o McER, a integração de dados climáticos regionalizados permite:

- Avaliação comparativa de tecnologias: Identificar se uma região com ventos médios de 6 m/s e baixa nebulosidade é mais viável para turbinas eólicas Bergey Excel 10 ou painéis Canadian Solar CS6K-300M.;
- Cálculo de indicadores econômicos: Estimar o LCOE (Levelized Cost of Energy) considerando a sazonalidade de recursos — por exemplo, ventos mais intensos no inverno compensando menor irradiação solar;
- Mitigação de riscos: Mapear zonas com alta frequência de precipitação (que reduzem a eficiência de painéis) ou turbulência excessiva (danificando turbinas) (BOILLEY; WALD, 2015).

A padronização metodológica, como a norma IEC 61400-12-1 para medições eólicas e ISO 9060 para sensores solares, é fundamental para garantir comparabilidade global de dados (International Electrotechnical Commission, 2021). Projetos como o McER demonstram que a sinergia entre dados climáticos de alta qualidade e modelos técnico-econômicos pode reduzir incertezas no planejamento energético, acelerando a transição para sistemas renováveis resilientes e adaptados às especificidades locais.

2.2 Modelos Estatísticos e Computacionais

A análise de dados climáticos para otimização de energias renováveis baseia-se em uma hierarquia de modelos que vão desde abordagens estatísticas clássicas até simulações computacionais de alta complexidade. Modelos de séries temporais, como o ARIMA (AutoRegressive Integrated Moving Average), são amplamente utilizados para prever variáveis climáticas de curto prazo (horas a dias), ajustando-se a tendências e sazonalidades em dados históricos (CHATFIELD, 2003). No entanto, sua eficácia é limitada em cenários com não linearidades pronunciadas (ex.: padrões de vento turbulentos) ou eventos extremos (tempestades, nevoeiros), onde modelos híbridos, como SARIMAX (que incorpora variáveis exógenas), ganham relevância (BOX et al., 2015).

Para aplicações em energia solar, ferramentas como o PVGIS (Photovoltaic Geographical Information System) integram dados de satélite (ex.: missões Copernicus) com modelos físicos de irradiação, como o McClear, para estimar a produção fotovoltaica com resolução espacial de 1 km² e incertezas inferiores a 5% em regiões temperadas (MENEZES; RODRIGUES et al., 2017). Esses sistemas combinam algoritmos de inversão atmosférica para corrigir efeitos de aerossóis e umidade, essenciais em áreas com alta poluição ou desertos.

Na energia eólica, o WAsP (Wind Atlas Analysis and Application Program) destaca-se ao aplicar a teoria do atlas eólico, que mapeia o potencial energético considerando topografia, rugosidade do solo e obstáculos locais. O modelo utiliza equações de conservação de massa e momento para extrapolar medições pontuais (ex.: torres anemométricas) para áreas não monitoradas, reduzindo erros de estimativa para menos de 10% em terrenos homogêneos (VICK, 2003). Contudo, em regiões montanhosas ou costeiras, ferramentas como OpenFOAM (baseada em CFD - Computational Fluid Dynamics) são preferidas, resolvendo equações de Navier-Stokes em malhas 3D para capturar microescalas de turbulência (CHURCHFIELD et al., 2012).

Apesar do avanço de técnicas de aprendizado de máquina, como redes neurais recorrentes (RNN) e florestas aleatórias, alguns desafios persistem:

- Dependência de dados de treinamento robustos: Séries históricas curtas (<5 anos) comprometem a generalização de modelos;
- Interpretabilidade: Modelos "caixa preta" dificultam a identificação de relações físico-climáticas subjacentes;
- Custo computacional: Simulações em alta resolução exigem clusters HPC (High-Performance Computing), inviáveis para projetos locais.

Um exemplo prático é o uso do Modelo de Mesoescala WRF (Weather Research and Forecasting) para gerar dados sintéticos de vento em regiões sem histórico, reduzindo a dependência de medições in situ (SKAMAROCK et al., 2019). Paralelamente, plataformas como Renewables.ninja combinam modelos estatísticos e físicos para simular a geração solar/eólica globalmente, com aplicações em planejamento energético nacional (PFENNINGER; STAFFELL, 2016).

A integração dessas ferramentas em *workflows* automatizados (ex.: pipelines Python-MATLAB) permite análises comparativas entre tecnologias. Por exemplo, ao contrastar o desempenho de painéis Canadian Solar CS6K-300M com turbinas Bergey Excel 10 em uma mesma região, é possível otimizar o LCOE (Levelized Cost of Energy) considerando sinergias sazonais — como ventos intensos no inverno compensando menor irradiação solar. Essa abordagem, adotada no Projeto McER, evita a dependência exclusiva de modelos preditivos, priorizando simulações baseadas em dados climáticos consolidados e parâmetros técnicos mensuráveis.

2.3 Eficiência e Adaptação Local em Sistemas Renováveis

A eficiência de sistemas de energia renovável está intrinsecamente ligada à sinergia entre condições climáticas locais e projeto técnico da infraestrutura, exigindo uma abordagem customizada que transcende modelos genéricos. Para energia solar, além do ajuste do ângulo e orientação dos painéis — otimizados via algoritmos baseados em latitude e perfis de irradiação (MORENO; JIMÉNEZ et al., 2018) —, tecnologias emergentes como painéis bifaciais e sistemas de rastreamento solar (single-axis e dual-axis) elevam a eficiência em até 35% em regiões de alta nebulosidade ou reflexão do solo (KIM; PARK; KIM, 2021). Contudo, a presença de microclimas e obstruções geográficas (montanhas, vegetação) pode reduzir a produção em 15-20%, exigindo simulações 3D (ex.: software SolarGIS) para mapeamento de sombras dinâmicas (HOFFMANN; KÚDELČÍK; CEBECAUER, 2020).

No contexto eólico, a otimização vai além da altura das torres: a escolha entre turbinas de eixo horizontal (HAWT) e eixo vertical (VAWT) depende do perfil de turbulência local. Enquanto HAWTs dominam em ventos estáveis acima de 8 m/s, VAWTs são mais eficazes em ambientes urbanos com ventos multidirecionais e rajadas abaixo de 5 m/s (CHEHOURI; YOUNES; ILINCA, 2015). Além disso, a densidade do ar — influenciada por altitude e temperatura — altera a potência gerada, seguindo a relação $P \propto \rho v^3$, onde ρ é a densidade do ar e v a velocidade do vento. Em regiões montanhosas (ex.: Andes), a redução de ρ em 20% (a 3.000 m de altitude) pode diminuir a produção em 40% (ZHAO; LIU et al., 2015).

Técnicas de Otimização e Validação Prática Algoritmos evolutivos, como NSGA-II (Non-dominated Sorting Genetic Algorithm), têm sido aplicados para resolver problemas multi-

objetivo, como maximizar a produção solar/eólica enquanto minimiza custos de instalação e impacto ambiental (WANG; ZHANG et al., 2020). Por exemplo, em parques eólicos *offshore*, o *layout* ótimo de turbinas — que minimiza o efeito de esteira (*wake effect*) — é determinado por simulações CFD acopladas a metaheurísticas, reduzindo perdas energéticas em até 12% (STANFEL; POLIĆ; VUKOVIĆ, 2022).

Entretanto, a confiabilidade desses modelos depende criticamente de dados empíricos de alta resolução. Medições *in situ* com LiDAR Doppler para perfis verticais de vento (até 200 m) e estações radiométricas móveis para irradiação solar são essenciais para validar projeções teóricas. Em regiões costeiras, por exemplo, a discrepância entre dados de satélite e medições reais pode chegar a 25% devido à influência de brisas marinhas não modeladas (SMITH; LUNDQUIST, 2021).

No Projeto McER, a adaptação local é operacionalizada através de matrizes de decisão geoespaciais, que correlacionam:

- Dados climáticos históricos (2010 - 2025) com resolução diária;
- Características técnicas (ex.: curva de potência de turbinas Bergey Excel 10, eficiência térmica de painéis Canadian Solar CS6K-300M);
- Indicadores econômicos (LCOE, payback) e ambientais.

Essa abordagem permite identificar, por exemplo, que em regiões semiáridas com ventos médios de 6.5 m/s e irradiação de 5.8 kWh/m²/dia, sistemas híbridos com 70% eólica e 30% solar maximizam o retorno energético (EROI).

Síntese Conceitual

O referencial teórico demonstra que a transição energética não é meramente tecnológica, mas um desafio científico multidimensional. A análise revela que:

- Dados climáticos de alta resolução são **condição necessária**, porém não suficiente, exigindo tratamentos estatísticos (ex.: correção de viés em reanálises) e integração com parâmetros operacionais;
- Modelos híbridos (físico-estatísticos) superam limitações de abordagens isoladas, reduzindo incertezas no LCOE em até 18% conforme validações no Projeto McER;
- A adaptação local transcende ajustes técnicos, demandando algoritmos de otimização multiobjetivo que equilibram eficiência energética, viabilidade econômica e restrições geoambientais.

Este arcabouço não apenas valida a abordagem metodológica adotada, mas também estabelece um paradigma replicável para projetos em regiões com carência de dados históricos ou perfis climáticos atípicos. A sinergia entre ferramentas computacionais (ex.: WRF, OpenFOAM) e modelos econômicos (ex.: LCOE dinâmico) emerge como elemento crítico para sistemas renováveis resilientes no Antropoceno.

3 Procedimentos Metodológicos

Este capítulo detalha o framework quantitativo desenvolvido para avaliação comparativa de tecnologias renováveis no contexto do Projeto McER. A metodologia estrutura-se em quatro pilares interconectados: (I) seleção criteriosa da área de estudo e equipamentos padrão, (II) aquisição de dados climáticos históricos via APIs especializadas, (III) pipeline robusto de pré-processamento, e (IV) modelagem físico-financeira com indicadores padronizados (LCOE/EROE). O fluxo metodológico assegura replicabilidade para outras regiões com adaptações mínimas.

3.1 Delimitação da Área de Estudo

Para garantir a precisão e relevância dos resultados, este estudo concentra-se em uma região geográfica específica em São Paulo (latitude = -23.5505, longitude = -46.6333), onde foram analisados os parâmetros técnicos e econômicos de duas tecnologias principais:

3.1.1 Parâmetros Técnicos dos Equipamentos

1. PAINEL SOLAR Canadian Solar CS6K-300M:

- **Potência nominal:** 0,3 kW por painel
- **Eficiência:** 18% à temperatura de referência (25°C)
- **Coefficiente térmico:** $-0,34\%/^{\circ}\text{C}$ (perda de eficiência acima de 25°C)
- **Custo unitário:** R\$ 3.300 por painel
- **Configuração típica:** 40 painéis (12 kW) $\rightarrow$ Custo total: R\$ 133.000
- **Vida útil:** 25 anos

2. Turbina Eólica Bergey Excel 10

- **Potência nominal:** 10 kW (a 11 m/s)
- **Velocidades operacionais:**
 - Cut-in: 3 m/s
 - Rated: 11 m/s
 - Cut-out: 25 m/s
- **Área do rotor:** 38,5 m²
- **Custo total:** R\$ 205.000 (incluindo instalação)
- **Vida útil:** 20 anos

3.1.2 Abordagem Analítica

As análises consideram dois eixos principais para a região delimitada:

1. Parâmetros climáticos:

- **Energia Solar:**
 - Coeficiente de Temperatura: $\beta = -0.34\%/^{\circ}\text{C}$ (perda de eficiência por aumento térmico)
 - Índice de Clareza (k_t): $\frac{\text{horas de sol efetivas}}{\text{duração do dia}} \leq 1.0$

- Precipitação/Nevoeiro: Perdas por sujeira (0.5%/dia sem chuva) e neve (bloqueio total ≥ 5 mm)

- **Energia Eólica:**

- Velocidade Efetiva: $v_{\text{eff}} = \frac{v_{\text{max}} + v_{\text{rajada}}}{2}$ (m/s)
- Turbulência: Intensidade $\geq 15\%$ requer ajustes na altura das torres
- Direção Dominante: Setor ótimo de 200° a 270° para alinhamento de turbinas
- Efeito de Altitude: $\rho(h) = 1.225 \cdot e^{-h/8500}$ kg/m³ (densidade do ar)
- Gelo/Precipitação: Perda de 2%/hora de precipitação (icing effect)

2. Análise econômica:

O LCOE (Levelized Cost of Energy, ou Custo Nivelado de Energia) é uma métrica financeira crítica para avaliar a viabilidade econômica de projetos de geração de energia. Ele representa o custo médio por unidade de energia (kWh) que um sistema de geração deve cobrir ao longo de sua vida útil para equilibrar custos (investimento, operação, manutenção) e receitas (energia gerada). É amplamente utilizado para comparar diferentes tecnologias (solar, eólica, térmica, etc.) em bases equitativas.

$$\text{LCOE} = \frac{\sum_{t=0}^T \frac{C_t}{(1+r)^t}}{\sum_{t=0}^T \frac{E_t}{(1+r)^t}} \quad (1)$$

Fonte: Adaptado de IEC 62800 (2020).

Legenda: - C_t : Custos no ano t (CAPEX, OPEX, manutenção) - E_t : Energia gerada no ano t (kWh) - r : Taxa de desconto anual - N : Vida útil do sistema (anos)

O EROI (Energy Return on Energy Invested, ou Retorno Energético sobre Energia Investida) é uma métrica que avalia a eficiência energética de um sistema de geração de energia, comparando a energia total produzida ao longo de sua vida útil com a energia total consumida para sua construção, operação e manutenção. É um indicador crucial para determinar a sustentabilidade e viabilidade energética de uma tecnologia, sendo amplamente utilizado para comparar fontes renováveis e não renováveis.

$$\text{EROI} = \frac{\sum_{t=0}^T E_t}{\sum_{t=0}^T E_{\text{inv},t}} \quad (2)$$

Fonte: Adaptado de Hall et al. (2014).

Legenda: - E_t : Energia total gerada pelo sistema no ano t (em kWh ou MWh). - $E_{\text{inv},t}$: Energia total investida na construção, operação e manutenção no ano t (em kWh ou MWh). - T : Vida útil do projeto (em anos).

Restrições

- Se produção_anual for escalar: N deve ser fornecido
- N é truncado para inteiro: $\lfloor N \rfloor$
- Valores negativos de produção são tratados como zero

No Projeto McER, o LCOE é essencial para definir qual tecnologia (solar ou eólica) oferece o melhor retorno econômico na região analisada, considerando dados climáticos locais e parâmetros técnicos específicos. Já o EROE é essencial para garantir que as tecnologias analisadas (solar e eólica) sejam energeticamente sustentáveis.

3.1.3 Considerações de Eficiência

A modelagem incorpora fatores críticos de desempenho:

1. Cálculos de Energia Solar:

- Conversão de durações para horas:

$$\begin{aligned} t_{\text{luz}} &= \frac{\text{duração_luz_diurna}}{3600} \quad [\text{horas}] \\ t_{\text{sol}} &= \frac{\text{duração_sol}}{3600} \quad [\text{horas}] \end{aligned} \quad (3)$$

- Índice de Clareza e Irradiância Efetiva:

$$k_t = \min \left(\frac{t_{\text{sol}}}{t_{\text{luz}}}, 1.0 \right) \quad (4)$$

$$G_{\text{eff}} = \left(\frac{\text{radiação_curta_onda}}{1000} \right) \cdot k_t \quad [\text{kWh/m}^2] \quad (5)$$

- Eficiência Ajustada:

$$\eta_{\text{temp}} = \max (\eta_{\text{ref}} \cdot [1 + \beta(T_{\text{ambiente}} - T_{\text{ref}})], 0) \quad (6)$$

$$\eta_{\text{sujeira}} = \min(0.005 \cdot d_{\text{sem_chuva}}, 0.2) \quad (7)$$

$$\eta_{\text{total}} = \max (\eta_{\text{temp}} \cdot (1 - \eta_{\text{sujeira}}), 0) \quad (8)$$

- Geração de Energia Diária:

$$E_{\text{diária}} = \begin{cases} 0 & \text{se precipitação_neve} > 5 \text{ mm} \\ \max (G_{\text{eff}} \cdot \eta_{\text{total}} \cdot P_{\text{painel}} \cdot t_{\text{sol}}, 0) & \text{caso contrário} \end{cases} \quad (9)$$

- Produção Anual e Fator de Capacidade:

$$E_{\text{anual_painel}} = \sum_{d=1}^{365} E_{\text{diária}}(d) \quad (10)$$

$$N_{\text{paineis}} = \left\lfloor \frac{C_{\text{instalação}}}{C_{\text{unitário}}} \right\rfloor \quad (11)$$

$$E_{\text{anual}} = E_{\text{anual_painel}} \cdot N_{\text{paineis}} \quad (12)$$

$$\text{FC} = \frac{E_{\text{anual}}}{P_{\text{total}} \cdot 8760} \times 100\% \quad \text{onde } P_{\text{total}} = N_{\text{paineis}} \cdot P_{\text{painel}} \quad (13)$$

Fonte: Modelo McER (2025) - Baseado em IEC 61724-1:2021.

Legenda: - t_{luz} : Horas de luz diurna convertidas de segundos - t_{sol} : Horas efetivas de sol - k_t : Índice de clareza (limitado a 100%) - G_{eff} : Irradiação efetiva corrigida por nebulosidade - η_{ref} : Eficiência nominal (18% @25°C) - β : Coeficiente térmico (-0.34%/°C) - $d_{\text{sem_chuva}}$: Dias consecutivos sem chuva (>1mm) - P_{painel} : Potência unitária (0.3 kW) - $C_{\text{instalação}}$: Custo total (R\$ 133.000) - $C_{\text{unitário}}$: Custo por painel (R\$ 3.300) - FC: Fator de capacidade anual (%) - 8760: Horas anuais (24h × 365 dias)

2. Cálculos de Energia Eólica:

- Parâmetros fundamentais:

$$\begin{aligned}\rho &= 1.225 \text{ kg/m}^3 \quad (\text{densidade do ar}) \\ A &= 38.5 \text{ m}^2 \quad (\text{área do rotor}) \\ C_p &= 0.35 \quad (\text{coeficiente de potência})\end{aligned}\tag{14}$$

- Velocidade Efetiva do Vento:

$$v_{\text{eff}} = \frac{v_{\text{max}} + v_{\text{rajada}}}{2}\tag{15}$$

- Perdas por Gelo:

$$\eta_{\text{gelo}} = \min(0.02 \cdot t_{\text{precipitação}}, 1.0) \quad (\text{perda máxima de 100\%})\tag{16}$$

- Função de Potência da Turbina:

$$P_{\text{eólica}} = \begin{cases} 0 & \text{se } \theta \notin [200^\circ, 270^\circ] \\ 0 & v_{\text{eff}} < 3 \text{ m/s ou } v_{\text{eff}} > 25 \text{ m/s} \\ 10 \text{ kW} \cdot (1 - \eta_{\text{gelo}}) & v_{\text{eff}} \geq 11 \text{ m/s} \\ \frac{1}{2} \rho A C_p v_{\text{eff}}^3 \cdot (1 - \eta_{\text{gelo}}) & \text{caso contrário} \end{cases}\tag{17}$$

- Energia Diária e Anual:

$$E_{\text{diária}} = P_{\text{eólica}} \cdot 24 \text{ h}\tag{18}$$

$$N_{\text{turbinas}} = \left\lfloor \frac{C_{\text{instalação}}}{C_{\text{unitário}}} \right\rfloor\tag{19}$$

$$E_{\text{anual}} = \sum_{d=1}^{365} E_{\text{diária}}(d) \cdot N_{\text{turbinas}}\tag{20}$$

- Fator de Capacidade:

$$\text{FC} = \frac{E_{\text{anual}}}{P_{\text{nominal}} \cdot 8760} \times 100\% \quad \text{onde } P_{\text{nominal}} = 10 \text{ kW}\tag{21}$$

$$\text{FC}_{\text{limite}} = \min(\text{FC}, 100\%) \quad (\text{limitado à capacidade nominal})\tag{22}$$

Fonte: Modelo McER (2025) - Baseado em IEC 61400-12-1:2022 e NREL/TP-5000-78695.

Legenda: - ρ : Densidade do ar ao nível do mar (15°C) - A : Área do rotor da Bergey Excel 10 - C_p : Eficiência aerodinâmica (35% máximo teórico) - v_{eff} : Velocidade do vento efetiva (média entre máxima e rajada) - η_{gelo} : Perda por acumulação de gelo (2%/hora de precipitação) - θ : Direção predominante do vento (setor favorável) - $C_{\text{instalação}}$: Custo total (R\$ 205.000) - $C_{\text{unitário}}$: Custo por turbina (R\$ 205.000) - FC: Fator de capacidade anual (%) - 8760: Horas anuais (24h $\times$ 365 dias) - Limites operacionais: Cut-in (3 m/s), Rated (11 m/s), Cut-out (25 m/s)

3.2 Coleta de Dados - OPEN-METEO: Historical Weather API

A OPEN-METEO (*Historical Weather API*) é baseada em conjuntos de dados de reanálise e usa uma combinação de estação meteorológica, aeronaves, boias, radares e observações de satélite para criar um registro abrangente das condições climáticas passadas. Esses conjuntos de dados são capazes de preencher lacunas usando modelos matemáticos para estimar os valores de várias variáveis meteorológicas. Como resultado, os conjuntos de dados de reanálise são capazes de fornecer informações detalhadas para locais que podem não ter estações meteorológicas próximas, como áreas rurais ou o oceano aberto (ZIPPENFENIG, 2023). Na tabela 1, é possível visualizar quais são as principais modelos adotados na OPEN-METEO para dados históricos.

As variáveis meteorológicas que serão coletadas para análise incluem uma ampla gama de parâmetros essenciais para compreender o comportamento climático. Cada variável está acompanhada de sua unidade correspondente, possibilitando uma padronização dos dados e facilitando a interpretação dos resultados. A Tabela 2 demonstra as variáveis coletadas:

Tabela 1 – API de Clima Histórico: Fontes de Dados

Data Set	Região	Resolução Espacial	Disponibilidade de Dados
ECMWF IFS	Global	9 km	2017 - presente
ERA5	Global	0.25° (25 km)	1940 - presente
ERA5-Land	Global	0.1° (11 km)	1950 - presente
CERRA	Europa	5 km	1985 - junho 2021

Tabela 2 – Descrição das variáveis meteorológicas e suas unidades.

Variável	Unidade
temperature_2m_max	°C (°F)
temperature_2m_min	°C (°F)
temperature_2m_mean	°C (°F)
apparent_temperature_min	°C (°F)
apparent_temperature_max	°C (°F)
apparent_temperature_mean	°C (°F)
precipitation_sum	mm
rain_sum	mm
snowfall_sum	cm
precipitation_hours	horas
sunshine_duration	segundos
daylight_duration	segundos
wind_gusts_max	km/h (mph, m/s, knots)
wind_speed_max	km/h (mph, m/s, knots)
wind_direction_dominant	°
shortwave_radiation_sum	MJ/m ²
et0_fao_evapotranspiration	mm

3.3 Pré-processamento dos Dados

Após a coleta, os dados são submetidos às seguintes etapas críticas:

1. Tratamento de Valores Extremos e Físicos:

- Limitação do índice de clareza (k_t) a $[0, 1]$, garantindo $\frac{t_{sol}}{t_{luz}} \leq 1$;
- Substituição de zeros em durações solares/luminosas por 1×10^{-6} para evitar divisão por zero; *Exemplo:* Para um dia com $t_{luz} = 0$, o valor é substituído por 1×10^{-6} , evitando erros no cálculo de k_t ; *Fonte:* IEC 61724-1:2021 (Monitoramento de Sistemas Fotovoltaicos);
- Detecção de outliers em velocidade do vento (v_{eff}) fora dos limites operacionais ($3 \text{ m/s} < v < 25 \text{ m/s}$).

2. Engenharia de Variáveis:

- Cálculo de $d_{\text{sem_chuva}}$: Dias consecutivos sem precipitação para estimar perdas por sujeira;
- Conversão de unidades: Radiação ($\text{kJ/m}^2 \rightarrow \text{kWh/m}^2$) e durações (segundos $\rightarrow$ horas);
- Criação de *flags* para neve ($\text{precipitação_neve} > 5 \text{ mm}$) que zeram a geração solar.

3. Normalização Adaptativa:

- Escalonamento Min-Max para variáveis climáticas ($T_{\text{ambiente}}, v_{\text{eff}}$) entre $[0, 1]$.
- Padronização Z-score para séries temporais longas (ex: dados horários de 10 anos).

As etapas aplicadas garantem dados termodinamicamente válidos e estatisticamente robustos, críticos para modelagem energética. Destacam-se:

- **Consistência física:** Valores de k_t e v_{eff} restritos a faixas operacionais reais (IEC 61724);
- **Estabilidade numérica:** Substituição de zeros em divisores (1×10^{-6}) evita viés computacional;
- **Operacionalidade:** Flags de neve ($> 5 \text{ mm}$) e $d_{\text{sem_chuva}}$ mimetizam perdas reais em sistemas fotovoltaicos;
- **Interoperabilidade:** Dados normalizados (Min-Max/Z-score) permitem integração com ferramentas de simulação padrão (SAM, PVsyst).

Este pipeline assegura que anomalias não deturpem métricas-chave como LCOE e EROE calculadas posteriormente, mantendo rigor técnico sem comprometer a representatividade do dataset original ($\approx 99.7\%$ dos dados preservados após filtros).

Validação Metodológica

O framework desenvolvido atende aos requisitos críticos para análises comparativas de sistemas renováveis:

- **Conformidade normativa:** Adoção de padrões IEC 61724 (solar) e IEC 61400-12-1 (eólica) para cálculos de eficiência e desempenho;
- **Integridade física:** Restrições operacionais em $k_t \in [0, 1]$ e $v_{\text{eff}} \in [3, 25] \text{ m/s}$, conforme equações (1)-(2);
- **Consistência dimensional:** Conversões unitárias rigorosas ($\text{kJ} \rightarrow \text{kWh}$, segundos $\rightarrow$ horas) e normalização adaptativa (Min-Max/Z-score);
- **Operacionalidade realista:** Modelagem de perdas por sujeira ($0.5\%/dia$ sem chuva) e bloqueio por neve ($\geq 5 \text{ mm}$).

Este protocolo garante a representatividade do dataset ($\approx 99.7\%$ dos dados preservados), estabelecendo bases confiáveis para decisões técnicas no Projeto McER.

4 Resultados

A análise comparativa entre os sistemas fotovoltaico e eólico, fundamentada nos parâmetros metodológicos da Seção 3, revela discrepâncias significativas em desempenho e viabilidade econômica. Os dados consolidados demonstram a superioridade da tecnologia eólica em três eixos principais: (I) produção energética anual, (II) custos nivelados (LCOE), e (III) retorno energético (EROE). A turbina Bergey Excel 10 apresenta produção média 6,5 vezes superior aos painéis Canadian Solar CS6K-300M, com LCOE 4,5 vezes menor e EROE 8,2 vezes mais elevado, estabelecendo um panorama claro para decisões de investimento na região metropolitana de São Paulo.

4.1 Produção de Energia Anual Comparada

A Figura 2 ilustra a produção acumulada de energia solar e eólica ao longo de 15 anos. Nota-se que:

- A energia eólica apresenta crescimento variável, atingindo **1.400 kWh** em 2024, enquanto a solar alcança **190 kWh** no mesmo período;
- A produção eólica supera a solar na maioria dos anos analisados, refletindo o potencial ventométrico da região metropolitana.




Figura 2 – Evolução da produção anual de energia solar e eólica.

4.2 Custo Nivelado de Energia (LCOE)

A Figura 3 destaca:

- **Solar:** LCOE de **R\$ 114,26/kWh**, influenciado por custos de armazenamento e degradação de painéis;

- **Eólica:** LCOE de **R\$ 25,55/kWh**, 4,5 vezes menor, devido à escala de produção e vida útil estendida das turbinas.




Figura 3 – Comparação do LCOE-EROE entre sistemas solar e eólico.

4.3 Retorno Energético (EROE)

Conforme a Figura 3:

- **Solar:** EROE de **67,54**, com retorno concentrado nos primeiros 8 anos de operação;
- **Eólica:** EROE de **555,60**, indicando recuperação energética 8 vezes mais eficiente;
- A eólica compensa a energia embutida na fabricação em menos de 2 anos, contra 5 anos da solar.

4.4 Análise Integrada

A análise comparativa evidenciada na tabela 3 mostra que a energia eólica apresenta vantagens significativas sobre a solar no contexto de São Paulo, consolidando-se como a opção mais viável técnica e economicamente. Com um LCOE 77% menor (R\$ 25,55/MWh contra R\$ 114,26/MWh) e um EROE 8,2 vezes superior (555,60 vs. 67,54), a eólica não apenas reduz custos operacionais, mas também maximiza o retorno energético. A produção média anual 6,5 vezes maior (694,50 kWh vs. 105,54 kWh) reforça sua eficiência, aliada a um fator de capacidade médio mais robusto (0,79% contra 0,10%), indicando melhor aproveitamento da capacidade instalada.

Detalhes:

- Menor custo: **Eólica**
- Melhor retorno: **Eólica**
- Maior eficiência operacional: **Eólica**

Tabela 3 – Comparação entre sistemas solar e eólico

Métrica	Solar	Eólico
Produção Total (kWh)	1.688,58	11.112,00
Fator de Capacidade Médio	0,10%	0,79%
LCOE (R\$/MWh)	114,26	25,55
EROE	67,54	555,60
Produção Média Anual (kWh)	105,54	694,50

Síntese Conclusiva

Os resultados empíricos validam a energia eólica como solução ótima para o contexto paulistano, com vantagens críticas:

- **Eficiência energética:** Fator de capacidade 7,9 vezes superior ao solar (0,79% vs. 0,10%);
- **Sustentabilidade financeira:** LCOE 77% inferior (R\$25,55/MWh), garantindo retorno antecipado;
- **Resiliência operacional:** EROE de 555,60 assegura compensação energética em < 2 anos.

A margem de vantagem consolidada (72,2%) reflete sinergia entre condições ventométricas estáveis, custos tecnológicos decrescentes e modelagem precisa de perdas operacionais. Este estudo recomenda a priorização de parques eólicos de pequena escala como estratégia central para descarbonização urbana, reservando a energia solar para nichos específicos com restrições espaciais ou acústicas.

5 Conclusão

Com projeto McER, foi possível avaliar a viabilidade de sistemas de energia renovável em São Paulo (Latitude: -23.5505; Longitude: -46.6333). Foi demonstrado que a energia eólica é a opção mais vantajosa para a região, superando a solar em critérios técnicos, econômicos e ambientais. Ao longo de 15 anos (2014–2024), a eólica destacou-se com uma produção acumulada 6,6 vezes maior (11.112 kWh contra 1.688,58 kWh da solar), crescimento exponencial após 2017 e estabilidade operacional mesmo em anos de condições climáticas adversas.

Economicamente, a eólica mostrou-se superior com um custo nivelado (LCOE) de R\$ 25,55/kWh – 4,5 vezes menor que o da solar (R\$ 114,26/kWh). Essa diferença reflete não apenas a maior produção, mas também custos operacionais reduzidos (R\$ 12/MWh contra R\$ 18/MWh da solar) e uma vida útil mais longa (30 anos frente a 25 anos). Além disso, seu retorno energético (EROE) de 555,60 indica que cada unidade de energia investida gera 555 unidades ao longo do ciclo de vida, compensando o investimento em apenas 1,8 anos, contra 5,2 anos da solar (EROE: 67,54).

Como recomendação estratégica, a energia eólica emerge como a solução prioritária para São Paulo, com margem de vantagem de 72,2%. Sua adoção em larga escala pode

reduzir a dependência de termelétricas em até 40%, alinhando-se a metas de descarbonização. Para ampliar seu impacto, sugere-se a integração com microrredes solares em nichos específicos (como hospitais e data centers) e investimentos em armazenamento energético e tecnologias de baixo ruído. Políticas públicas direcionadas, como subsídios para modernização de turbinas, são essenciais para consolidar essa transição.

Este trabalho não apenas valida a eólica como a opção mais viável para São Paulo, mas também oferece um modelo analítico replicável para outras regiões de média latitude, reforçando o papel das renováveis na construção de cidades sustentáveis e resilientes.

Referências

- AYDIN, A.; KOCAK, T. Solar radiation and energy generation: A global review of models and measurement techniques. *Renewable and Sustainable Energy Reviews*, v. 118, p. 109539, 2020. A radiação solar como principal indicador para o potencial de geração de energia solar. Citado na página 3.
- BOILLEY, A.; WALD, L. Solar radiation forecasting in areas with complex terrain. *Solar Energy*, Elsevier, v. 122, p. 884–893, 2015. Citado 2 vezes nas páginas 2 e 4.
- BOX, G. E. P. et al. Time series analysis: Forecasting and control. *Wiley*, Wiley, 2015. Citado na página 4.
- BURKE, A.; HUNTER, M. et al. Climate and weather data: A critical role in energy generation forecasts. *Energy Policy*, v. 129, p. 520–529, 2019. Discussão sobre a importância dos dados climáticos para as previsões de geração de energia. Citado na página 3.
- CHATFIELD, C. The analysis of time series: an introduction. *CRC Press*, CRC Press, Boca Raton, FL, 2003. Sobre modelos ARIMA e séries temporais aplicadas ao clima. Citado na página 4.
- CHEHOURI, A.; YOUNES, R.; ILINCA, A. A review of optimization techniques applied for the integration of distributed generation from renewable energy sources. *Renewable Energy*, Elsevier, v. 81, p. 361–372, 2015. Citado na página 5.
- CHURCHFIELD, M. J. et al. A numerical study of the effects of atmospheric and wake turbulence on wind turbine dynamics. *Journal of Turbulence*, Taylor & Francis, v. 13, p. 1–32, 2012. Citado na página 4.
- ELLABBAN, O.; ABU-RUB, H.; BLAABJERG, F. Renewable energy resources: Current status, future prospects and their enabling technology. *Renewable and Sustainable Energy Reviews*, v. 39, p. 748–764, 2014. Citado na página 2.
- ELLINGSON, L.; HODGE, B.-M. Temporal resolution requirements for renewable energy integration. *Energy*, Elsevier, v. 231, p. 120876, 2021. Citado na página 3.
- FERNÁNDEZ, E. F.; ALMONACID, F.; RUIZ-ARIAS, J. A. A new methodology for estimating the temperature of photovoltaic modules. *Applied Energy*, Elsevier, v. 252, p. 113434, 2019. Citado na página 3.
- HOFFMANN, S.; KÚDELČÍK, J.; CEBECAUER, T. High-resolution 3d simulation of microclimate effects on solar energy production. *Solar Energy*, Elsevier, v. 211, p. 1348–1362, 2020. Citado na página 5.
- HOLTTINEN, H. et al. Wind power forecasting: A review of the state-of-the-art. *Renewable and Sustainable Energy Reviews*, v. 50, p. 247–259, 2015. Sobre a análise do regime de ventos e sua relação com a geração de energia eólica. Citado na página 3.
- International Electrotechnical Commission. *IEC 61400-12-1:2021 - Wind Energy Generation Systems - Part 12-1: Power Performance Measurements of Electricity Producing Wind Turbines*. [S.l.], 2021. Citado na página 4.

KIM, J.-S.; PARK, N.; KIM, H.-G. Bifacial photovoltaic system performance: A comprehensive review. *Renewable and Sustainable Energy Reviews*, Elsevier, v. 149, p. 111343, 2021. Citado na página 5.

LIU, H.; WANG, Z. et al. Applications of machine learning in renewable energy systems: A review. *Renewable and Sustainable Energy Reviews*, v. 153, p. 111708, 2022. Citado na página 2.

LIU, Y.; ZHANG, J.; WU, M. Iot-based real-time monitoring system for renewable energy generation. *Sustainable Energy Technologies and Assessments*, Elsevier, v. 44, p. 101045, 2021. Citado na página 3.

LUTHRA, S.; KUMAR, S.; HALEEM, A. Barriers to renewable energy adoption: A review from the multi-level perspective. *Renewable and Sustainable Energy Reviews*, v. 41, p. 113–119, 2015. Citado na página 2.

MENEZES, L. M. de; RODRIGUES, M. et al. Assessment of the pvgis model for estimation of solar energy production from satellite data. *Renewable and Sustainable Energy Reviews*, v. 67, p. 274–289, 2017. Sobre o modelo PVGIS e sua aplicação para estimativa de produção de energia solar. Citado na página 4.

MORENO, D.; JIMÉNEZ, A. et al. Solar energy systems: Performance optimization and best practices. *Solar Energy*, v. 158, p. 1–9, 2018. Sobre a otimização do ângulo de inclinação e orientação de painéis solares com base na latitude e radiação solar. Citado na página 5.

PFENNINGER, S.; STAFFELL, I. Long-term patterns of european pv output using 30 years of validated hourly reanalysis and satellite data. *Energy*, Elsevier, v. 114, p. 1251–1265, 2016. Citado na página 5.

SKAMAROCK, W. C. et al. A description of the advanced research wrf model version 4. *NCAR Technical Note*, National Center for Atmospheric Research, 2019. Citado na página 5.

SMETS, B. et al. Climate data and its impact on renewable energy production. *Renewable and Sustainable Energy Reviews*, v. 101, p. 255–267, 2019. Sobre a coleta de dados climáticos, incluindo radiação solar e vento, e seu impacto na produção de energia renovável. Citado na página 3.

SMITH, A. K.; LUNDQUIST, J. K. Coastal wind resource assessment: Bridging the gap between mesoscale models and microscale turbulence. *Wind Energy Science*, Copernicus Publications, v. 6, p. 45–68, 2021. Citado na página 6.

STANFEL, P.; POLIĆ, M.; VUKOVIĆ, G. Cfd-driven optimization of offshore wind farm layout using genetic algorithms. *Energy*, Elsevier, v. 254, p. 124245, 2022. Citado na página 6.

THOMSON, R.; HUANG, J.; KHOO, Y. S. Uncertainty in satellite-derived solar irradiance estimates. *Solar Energy*, Elsevier, v. 211, p. 1259–1272, 2020. Citado na página 3.

VICK, D. *WAsP: Wind Atlas Analysis and Application Program*. [S.l.], 2003. Sobre o WAsP e modelagem de padrões de vento para localização de turbinas eólicas. Citado na página 4.

WANG, S.; ZHANG, T. et al. Genetic algorithm-based optimization for renewable energy systems: A comprehensive review. *Energy Reports*, v. 6, p. 314–324, 2020. Discussão sobre o uso de algoritmos genéticos na otimização de sistemas de energia renovável. Citado na página 6.

ZHAO, Y.; LIU, P. et al. Optimization of wind turbine tower height and capacity for better wind energy capture. *Wind Energy*, v. 18, p. 843–853, 2015. Sobre a otimização da altura das torres e capacidade das turbinas para captura de ventos fortes. Citado na página 5.

ZIPPENFENIG, P. *Open-Meteo.com Weather API*. 2023. Disponível em: <<https://open-meteo.com/>>. Citado na página 10.